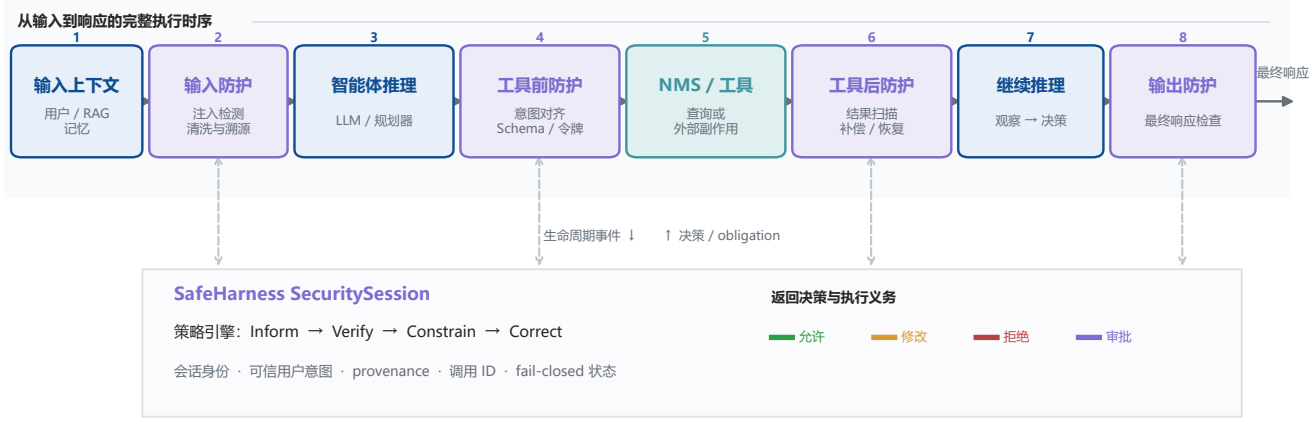
# SafeHarness 在智能体执行过程中提供安全能力

智能体负责理解、推理与规划；SafeHarness 在关键边界检查、授权、阻断、审计与恢复。

## a 智能体运行时安全注入路径




## b 安全能力由可插拔服务支撑

| | | |
|---|---|---|
| **语义 Judge**<br>注入与意图对齐 | **工具目录**<br>可信描述与 Schema | **签名能力授权**<br>单次令牌 / 防重放 |
| **人工审批**<br>高风险动作确认 | **审计后端**<br>最小化事件与回执 | **状态 / 补偿**<br>检查点与恢复语义 |

当前 Demo 多为内存实现；生产环境需外置网关、密钥隔离与持久化后端。

## c 职责与安全边界

**智能体：决定“做什么”**

理解任务 · 推理规划
选择工具 · 生成回答

**SafeHarness：执行安全裁决**

决定能否及如何执行
检查 · 授权 · 阻断 · 审计 · 恢复

**部署边界**

当前 Alpha：进程内控制 | 生产：独立工具网关 + 持久化审计 / 状态